Структура PDF-документа

Практическое руководство по извлечению заголовков и элементов

1. Введение

Формат PDF описывает не документ, а способ его отображения на странице. Поэтому надёжное определение заголовков — это всегда комбинация типографики, геометрии и, если повезёт, логической разметки самого файла. Ниже разобраны оба подхода и то, как они сочетаются в ридере Folio.

1.1. Типографические признаки

Кегль, насыщенность и гарнитура шрифта дают основной сигнал. Заголовок первого уровня обычно крупнее основного текста в 1,5–2 раза, подзаголовок — в 1,2–1,4. Дополнительно учитываются вертикальные просветы и нумерация вида «1.2.3».

1.2. Логическая разметка

Тегированные PDF содержат дерево структуры: элементы H1…H6, P, LI, Table. Если файл размечен, уровень заголовка берётся непосредственно из дерева и не требует эвристик. На практике размечено меньшинство документов.

Список признаков заголовка

- размер шрифта больше медианного по странице;
- насыщенность выше основной;
- одиночная короткая строка с отбивкой;
- нумерация или римская цифра в начале строки.

Рис. 1. Пример подписи к иллюстрации

2. Сильное нажатие и словарь

Сильное нажатие (force click) на слове вызывает системную панель определения — ровно так же, как в Preview и Books. Приложение получает событие давления с этапом 2 и передаёт слово в NSView.showDefinition(for:at:). Система сама показывает словарь, подбирает статью и запоминает источник.

2.1. Как это устроено

Нажатие начинается как обычный mouseDown. Пока палец давит сильнее, приходят события pressureChange: сначала этап 1 («нажатие»), затем этап 2 («сильное нажатие»). На этапе 2 вызывается словарь, этап 0 завершает жест.

2.2. Требования к железу

Нужен трекпад с Force Touch и включённым в системных настройках «Сильное нажатие и тактильный отклик». На обычной мыши остаётся сочетание ⌘D.

3. Пример кода

```
override func pressureChange(with event: NSEvent) {
    if event.stage == 2 {
        lookUpWord(at: lastPressPoint)
    }
}
```

Рис. 2. Фрагмент обработки сильного нажатия

3.1. Словарь терминов

Словарь — системная служба macOS, доступная любому приложению. Определение — статья словаря для выбранного слова. Разметка — набор прямоугольников и типов элементов, восстановленный по странице.

3.2. Что дальше

Следующие шаги: озвучивание текста, ссылки между страницами, аннотации и сохранение прогресса чтения. Всё это опирается на ту же разметку блоков.

Литература

[1] ISO 32000-1:2008. Document management — Portable Document Format.
[2] PDF 1.7 Reference, Adobe Systems, 2006.
[3] Apple. NSView.showDefinition(for:at:). AppKit Documentation.